SDCC
中国软件开发者大会
SOFTWARE DEVELOPER CONFERENCE CHINA

CSDN
全球最大中文IT社区

机器学习在美团用户画像中的应用

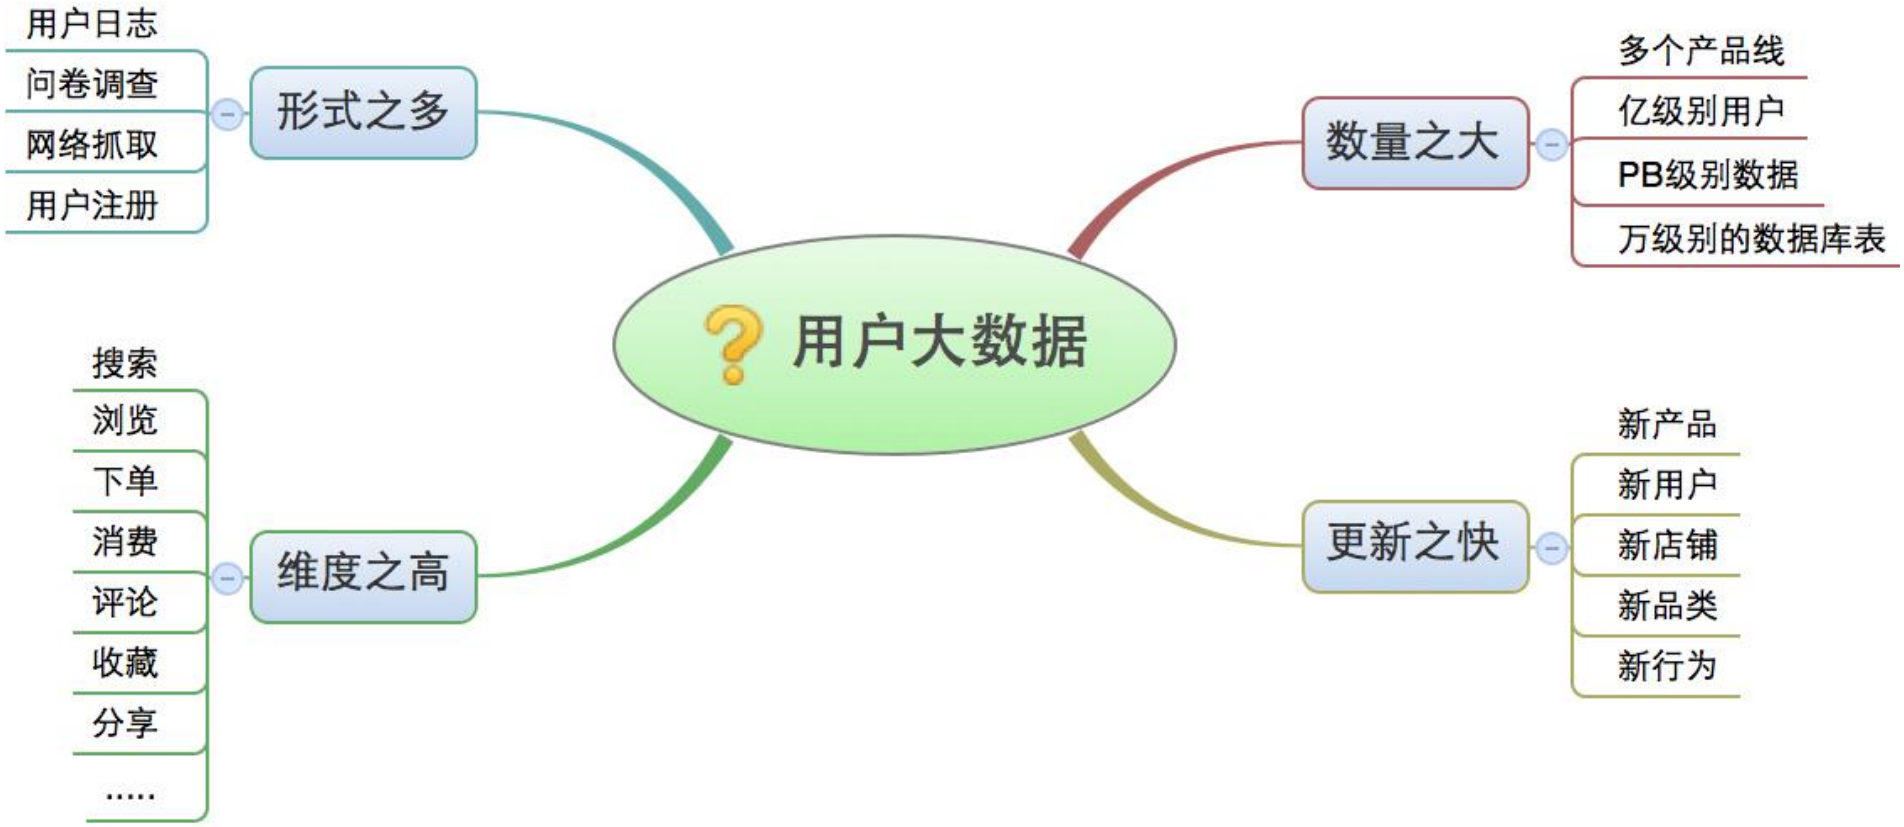
付晴川
fuqingchuan@meituan.com
2015-11-21

什么是用户画像？

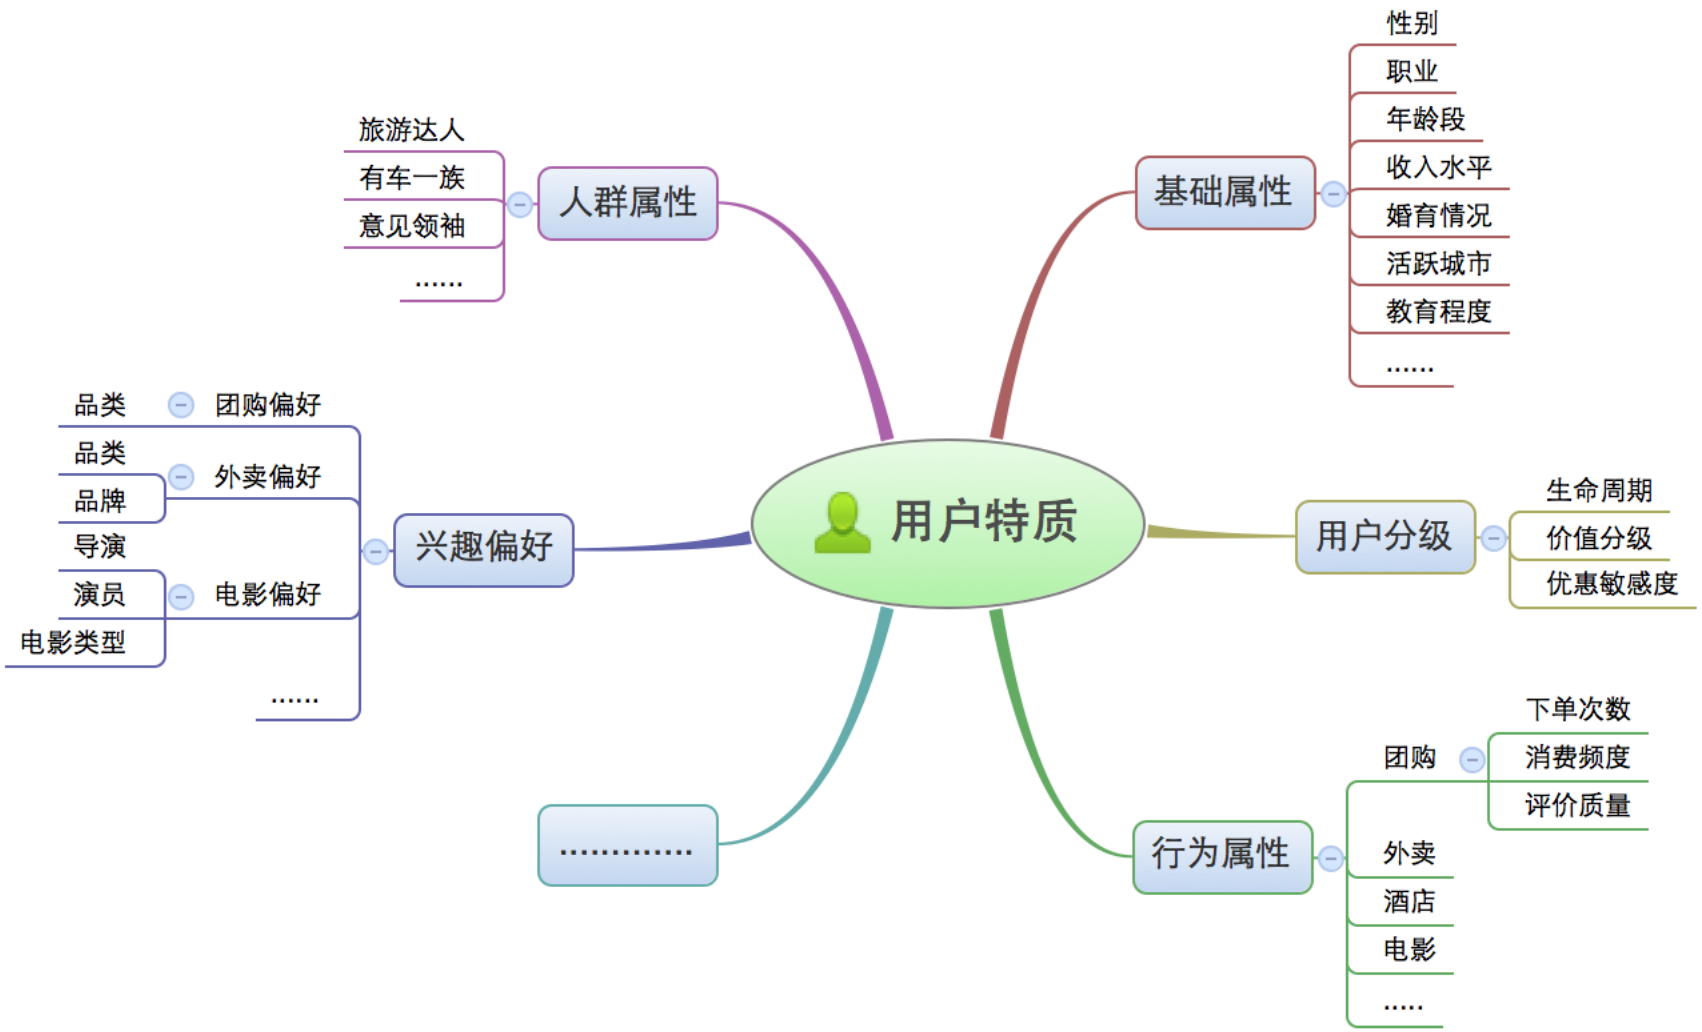
为什么要做用户画像？

如何做用户画像？

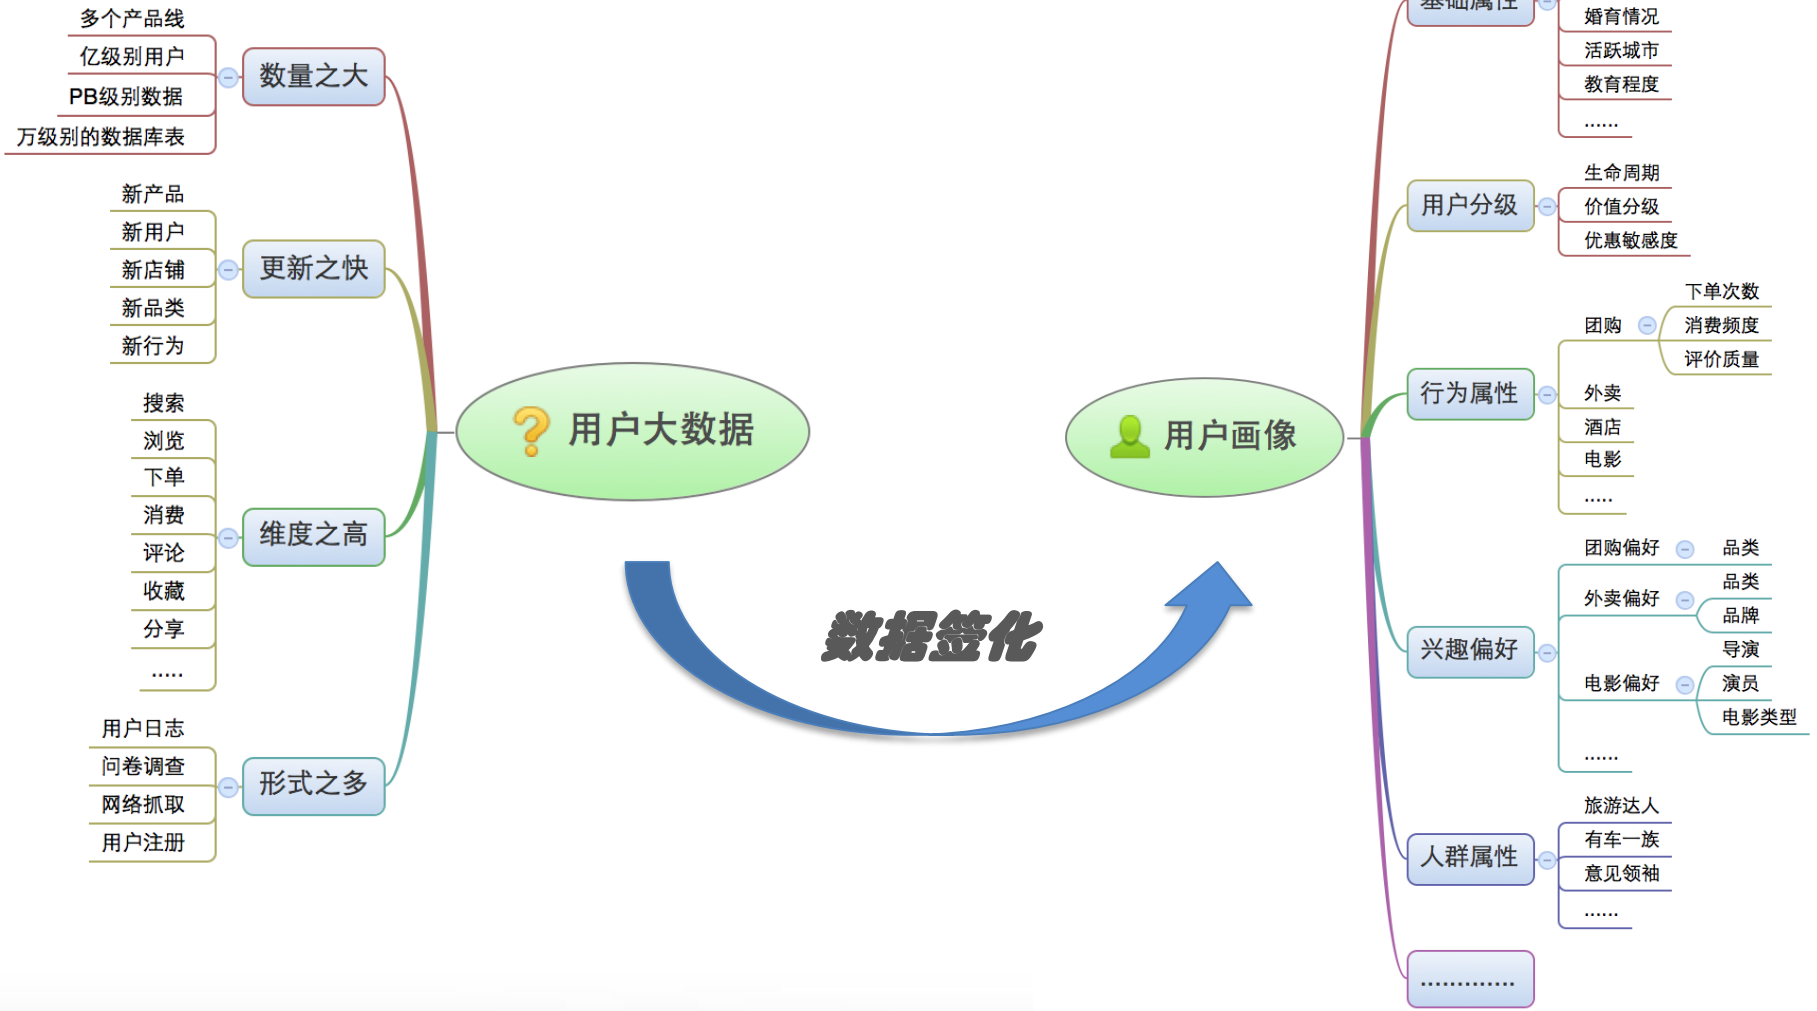
什么是用户画像?


用户大数据
形式之多
用户日志
问卷调查
网络抓取
用户注册
数量之大
多个产品线
亿级别用户
PB级别数据
万级别的数据库表
维度之高
搜索
浏览
下单
消费
评论
收藏
分享
.....
更新之快
新产品
新用户
新店铺
新品类
新行为

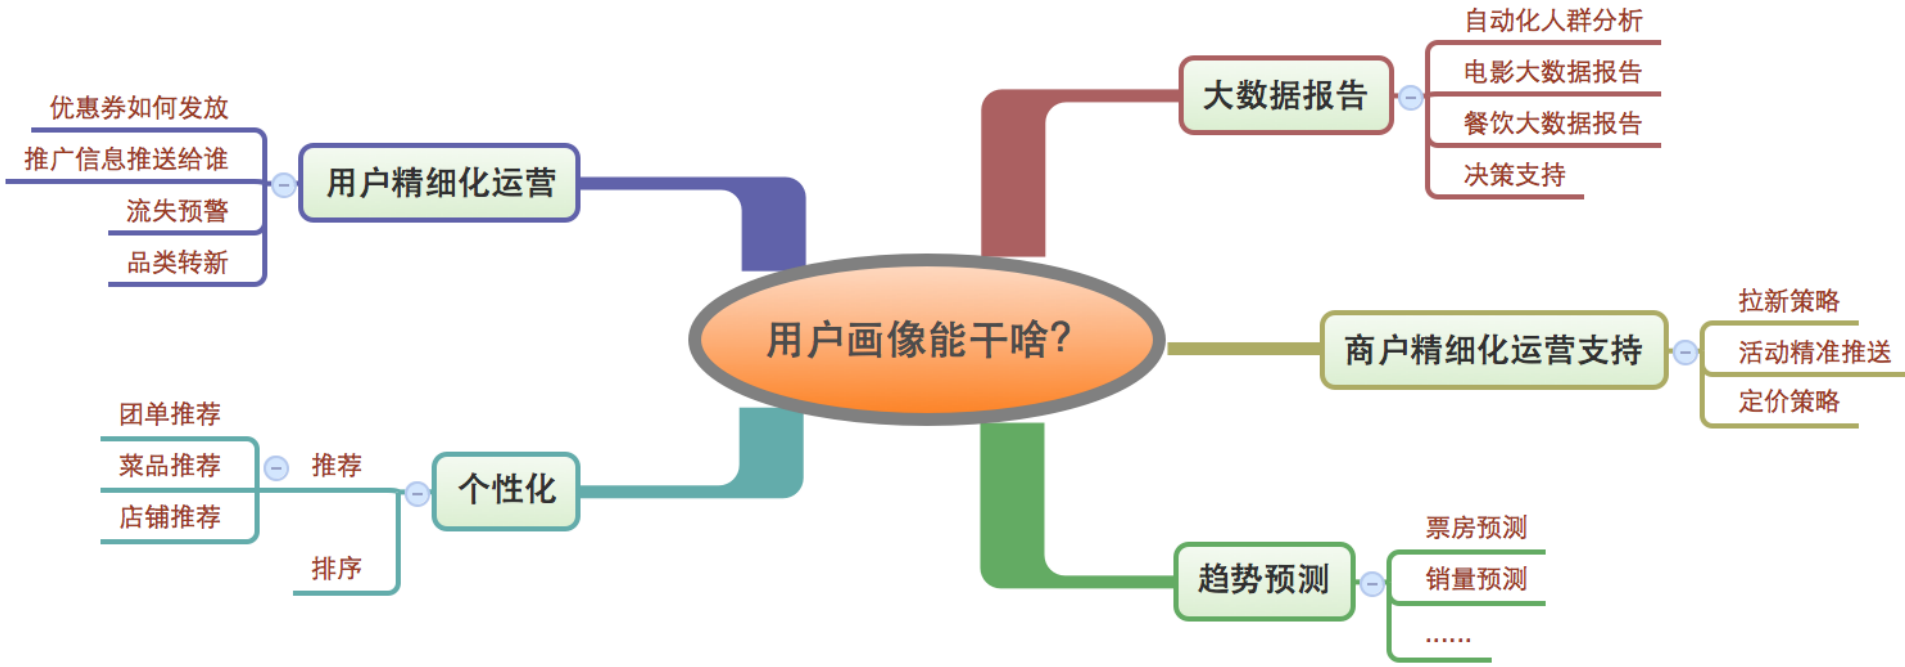
什么是用户画像?


用户特质
人群属性
旅游达人
有车一族
意见领袖
……
基础属性
性别
职业
年龄段
收入水平
婚育情况
活跃城市
教育程度
……
兴趣偏好
团购偏好
品类
外卖偏好
品类
品牌
电影偏好
导演
演员
电影类型
……
用户分级
生命周期
价值分级
优惠敏感度
行为属性
团购
下单次数
消费频度
评价质量
外卖
酒店
电影
……
……

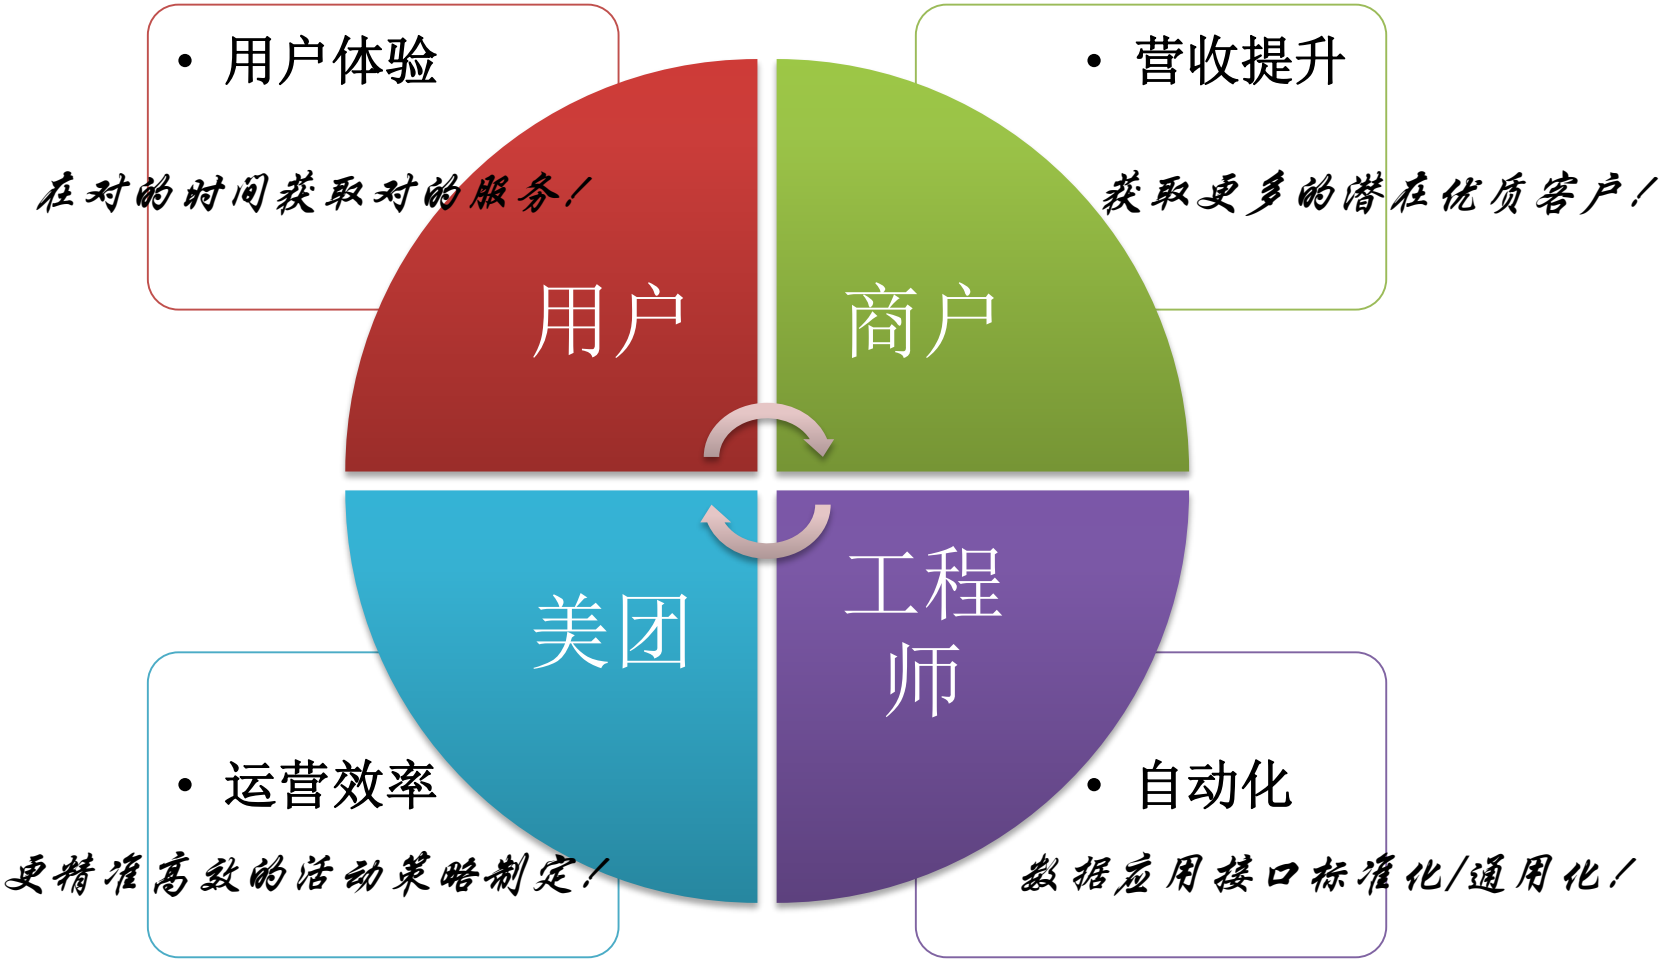
什么是用户画像?


用户大数据
数量之大
多个产品线
亿级别用户
PB级别数据
万级别的数据库表
更新之快
新产品
新用户
新店铺
新品类
新行为
维度之高
搜索
浏览
下单
消费
评论
收藏
分享
.....
形式之多
用户日志
问卷调查
网络抓取
用户注册
数据签化
用户画像
基础属性
性别
职业
年龄段
收入水平
婚育情况
活跃城市
教育程度
.....
用户分级
生命周期
价值分级
优惠敏感度
行为属性
团购
下单次数
消费频度
评价质量
外卖
酒店
电影
.....
兴趣偏好
团购偏好
品类
外卖偏好
品类
品牌
电影偏好
导演
演员
电影类型
.....
人群属性
旅游达人
有车一族
意见领袖
.....
.....

为什么需要用户画像？


用户画像能干啥?
用户精细化运营
优惠券如何发放
推广信息推送给谁
流失预警
品类转新
个性化
推荐
团单推荐
菜品推荐
店铺推荐
排序
大数据报告
自动化人群分析
电影大数据报告
餐饮大数据报告
决策支持
商户精细化运营支持
拉新策略
活动精准推送
定价策略
趋势预测
票房预测
销量预测
.....

为什么需要用户画像？


• 用户体验
在对的时间获取对的服务！
• 营收提升
获取更多的潜在优质客户！
用户
商户
美团
工程师
• 运营效率
更精准高效的活动策略制定！
• 自动化
数据应用接口标准化/通用化！

如何来做用户画像?

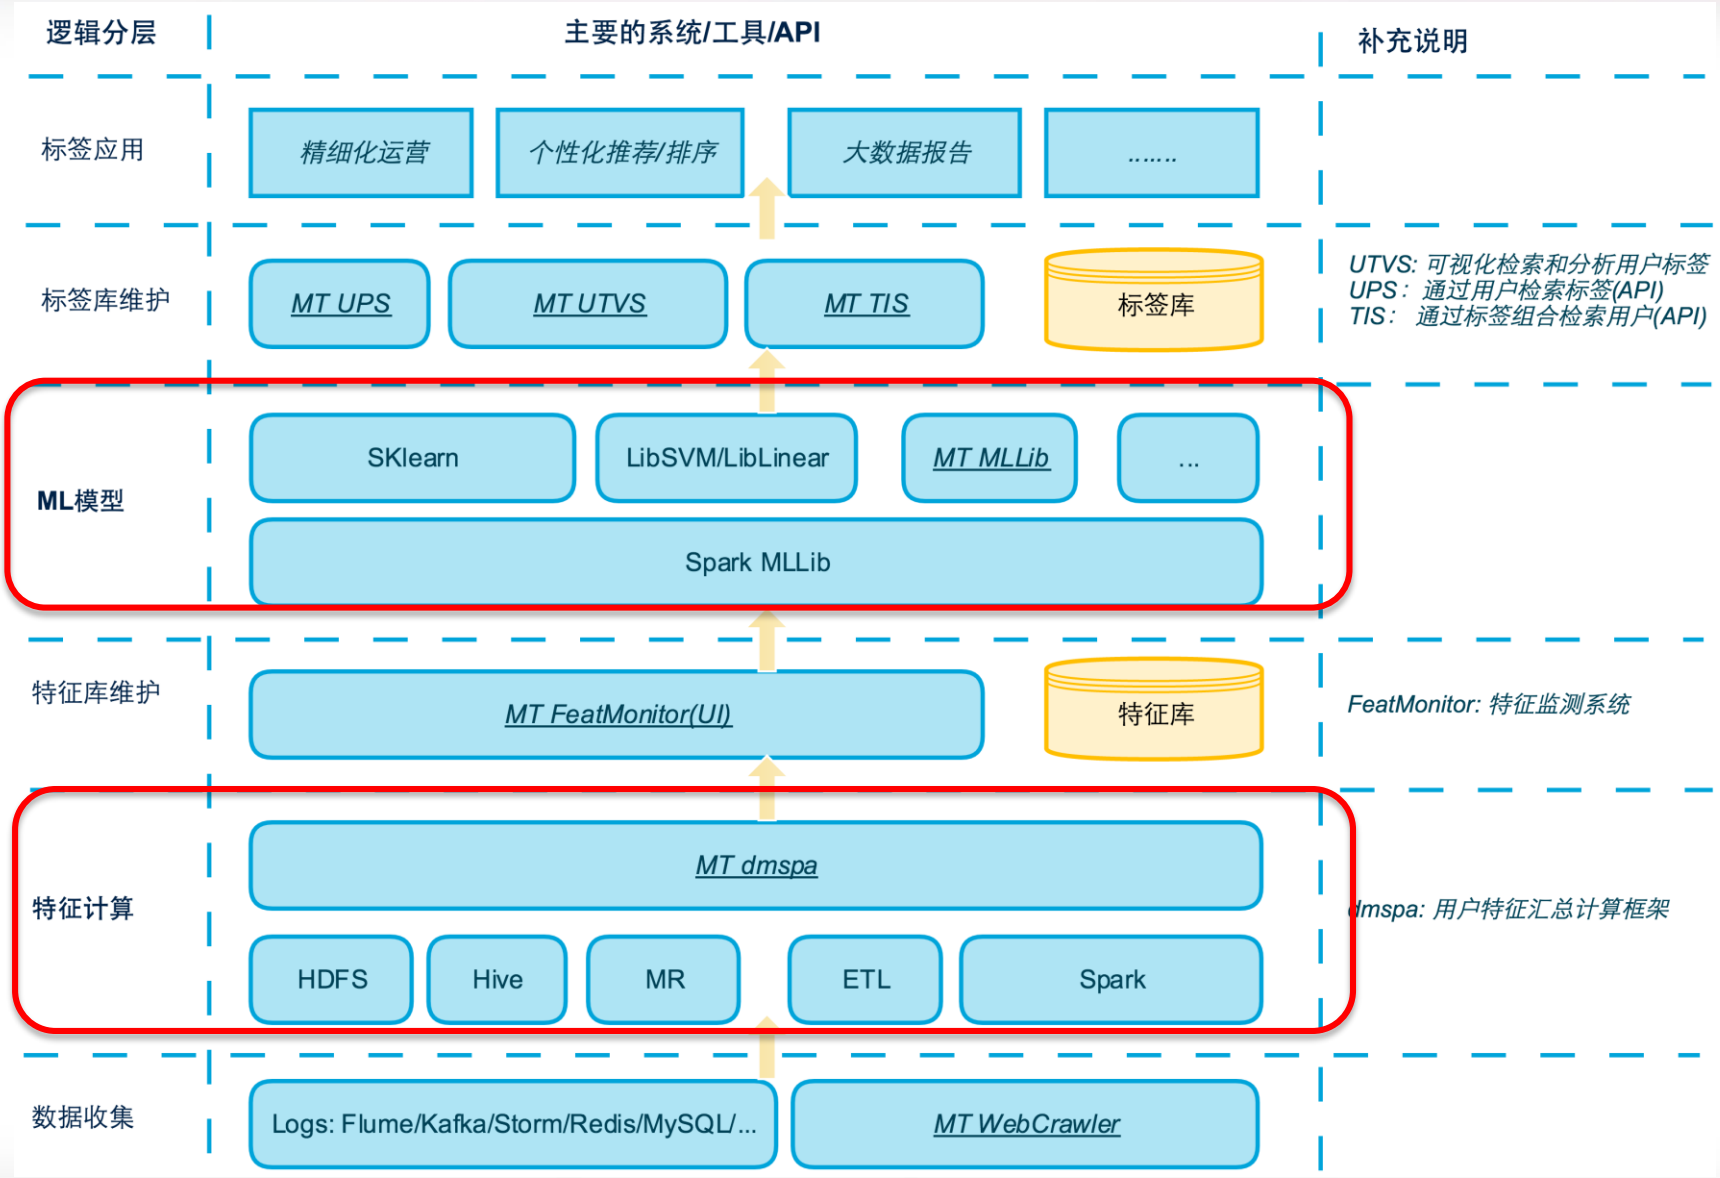
架构

算法

- 特征
- 模型

实践问题

架构 – 系统概览


逻辑分层
主要的系统/工具/API
补充说明
标签应用
精细化运营
个性化推荐/排序
大数据报告
……
标签库维护
MT UPS
MT UTVS
MT TIS
标签库
UTVS: 可视化检索和分析用户标签
UPS：通过用户检索标签(API)
TIS：通过标签组合检索用户(API)
ML模型
SKlearn
LibSVM/LibLinear
MT MLLib
...
Spark MLLib
特征库维护
MT FeatMonitor(UI)
特征库
FeatMonitor: 特征监测系统
特征计算
MT dmspa
HDFS
Hive
MR
ETL
Spark
dmspa: 用户特征汇总计算框架
数据收集
Logs: Flume/Kafka/Storm/Redis/MySQL/...
MT WebCrawler

架构——细节解读

MT dmspa

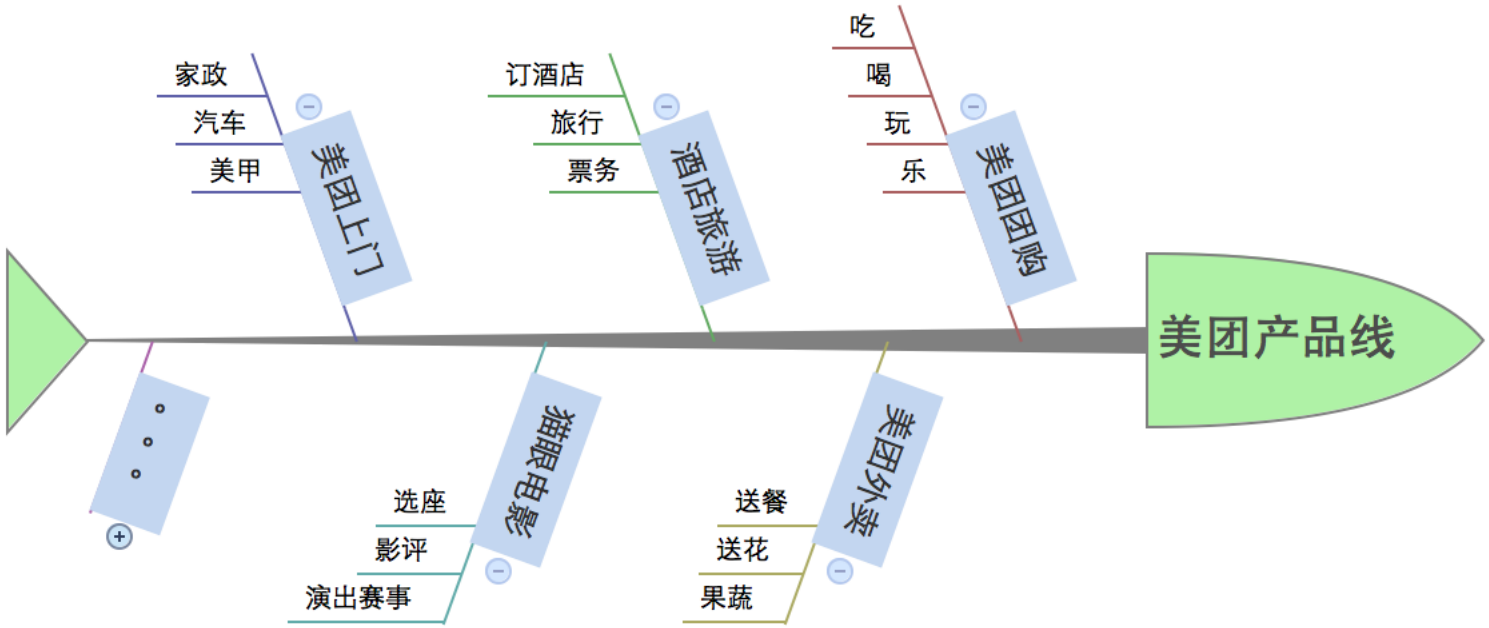
项目	统一特征提取框架
动机	1. 多工程师/多个模型“自给自足”，特征分散。 2. 存在人力/计算资源冗余。
实现	1. 特征统一提取/集中存储——大一统特征库。 2. 支持no-coding/配置化提特征。
效果	1. 建模周期: 3~4周下降到1~2周。 2. 人力/计算冗余减少2倍（估算值）

SDCC 中国软件开发者大会
SOFTWARE DEVELOPER CONFERENCE CHINA

MT utvs系列

项目	用户画像统一接口多系统项目
动机	1.数据挖掘成果需要友好统一的输出接口: 可视化+API
实现	1. 用户标签体系WEB可视化 2. 用户标签索引/实时查询 3. 报表自动化
效果	1. 成果推广加速/沟通成本降低 2. 传统用户问卷调查报报告周期1个月，utvs系统10分钟!

算法 – 用户特征



需要做横跨多个产品线的特征提取!

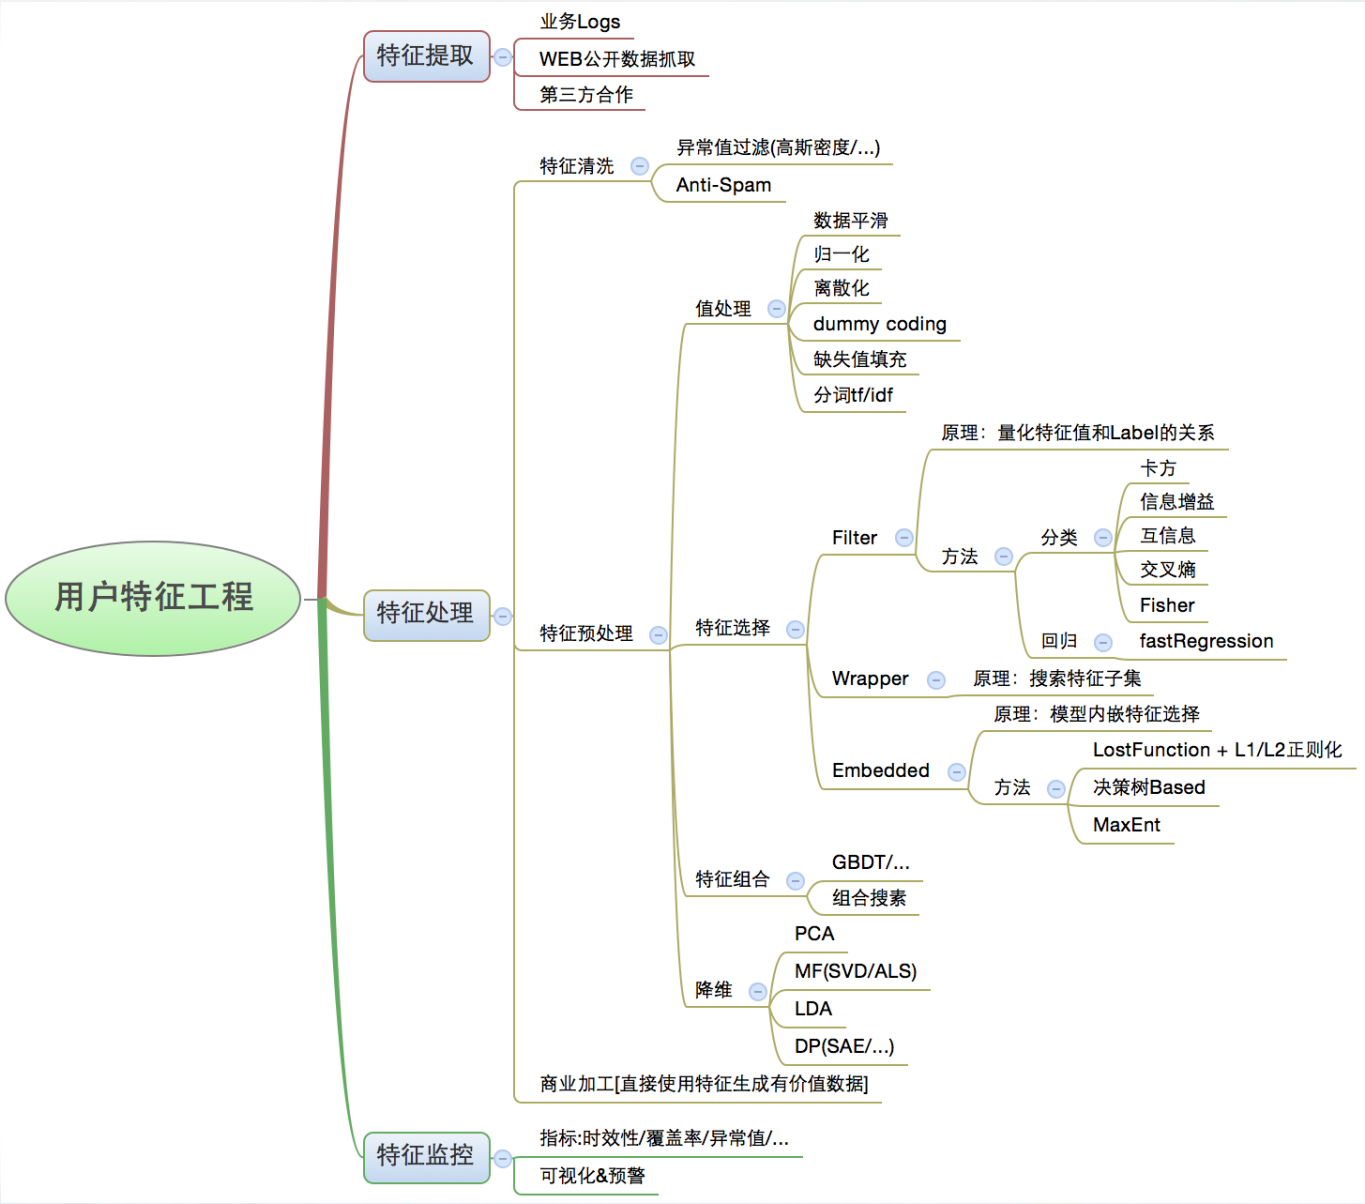
算法 – 用户特征

用户特征体系

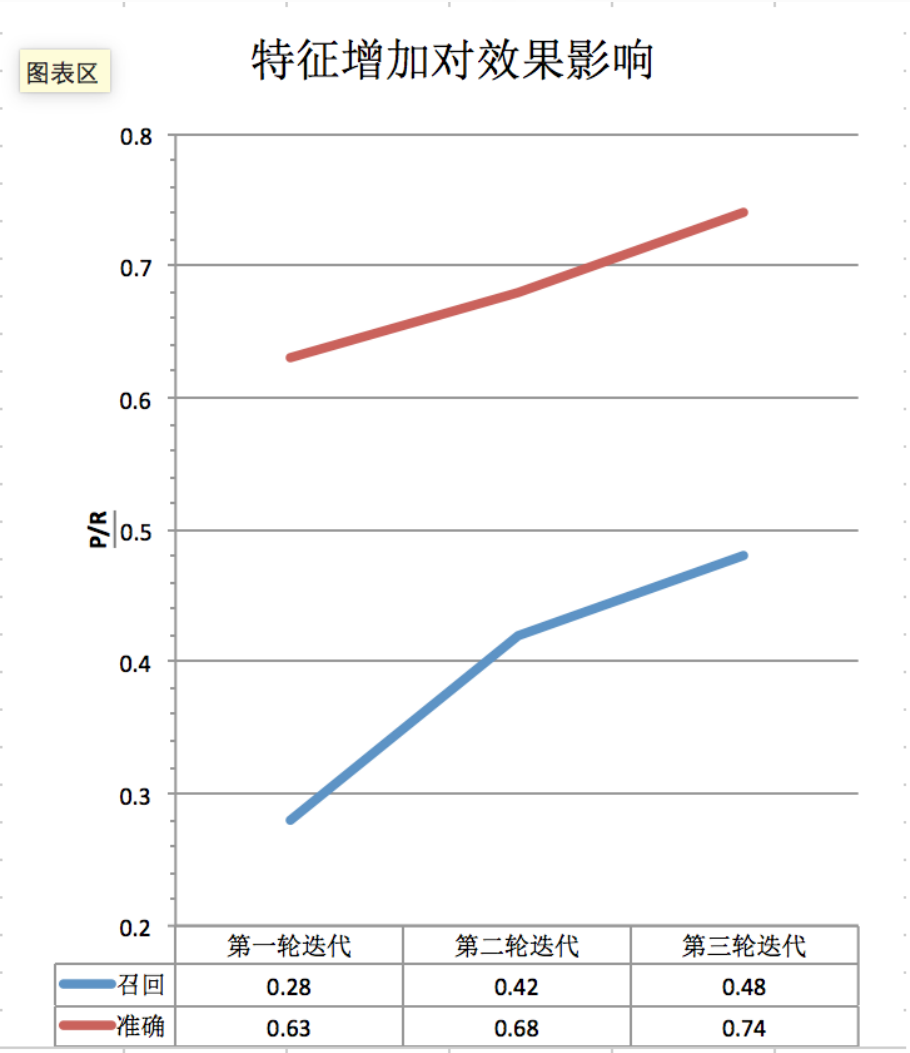
一级/业务	二级/行为	三级/时间	自由级/可选
基本 团购 外卖 酒店 电影 上门 ……	注册 登陆 浏览 下单 搜索 收藏 评论 消费 分享 LBS ……	年 月 日 周 早 中 晚 周末 工作日 节假日 …… + 每 + 最近	品类 品牌 词条 …

*M x N x K x L = ? 特征**膨胀***

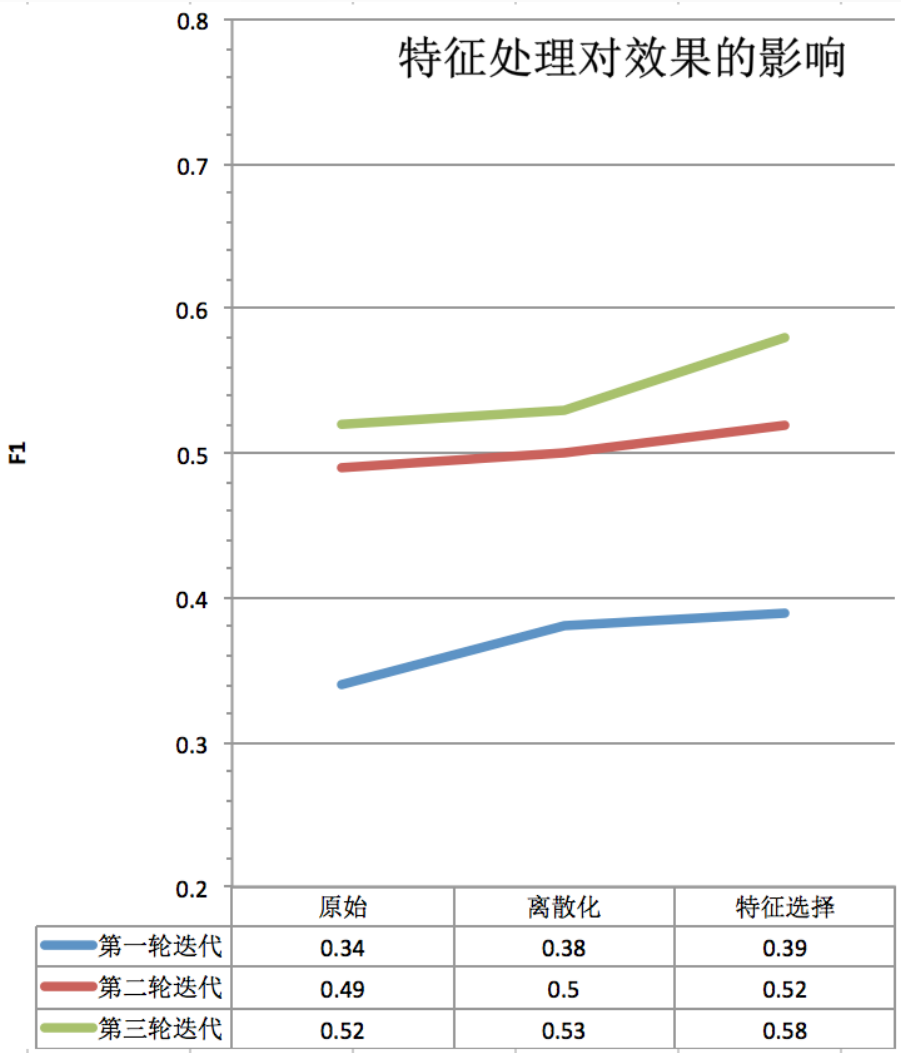
算法 – 用户特征


用户特征工程
特征提取
业务Logs
WEB公开数据抓取
第三方合作
特征处理
特征预处理
特征清洗
异常值过滤(高斯密度/...)
Anti-Spam
特征选择
值处理
数据平滑
归一化
离散化
dummy coding
缺失值填充
分词tf/idf
Filter
原理：量化特征值和Label的关系
方法
分类
卡方
信息增益
互信息
交叉熵
Fisher
回归
fastRegression
Wrapper
原理：搜索特征子集
Embedded
原理：模型内嵌特征选择
方法
LostFunction + L1/L2正则化
决策树Based
MaxEnt
特征组合
GBDT/...
组合搜索
降维
PCA
MF(SVD/ALS)
LDA
DP(SAE/...)
商业加工[直接使用特征生成有价值数据]
特征监控
指标:时效性/覆盖率/异常值/...
可视化&预警

算法 – 特征与效果实例



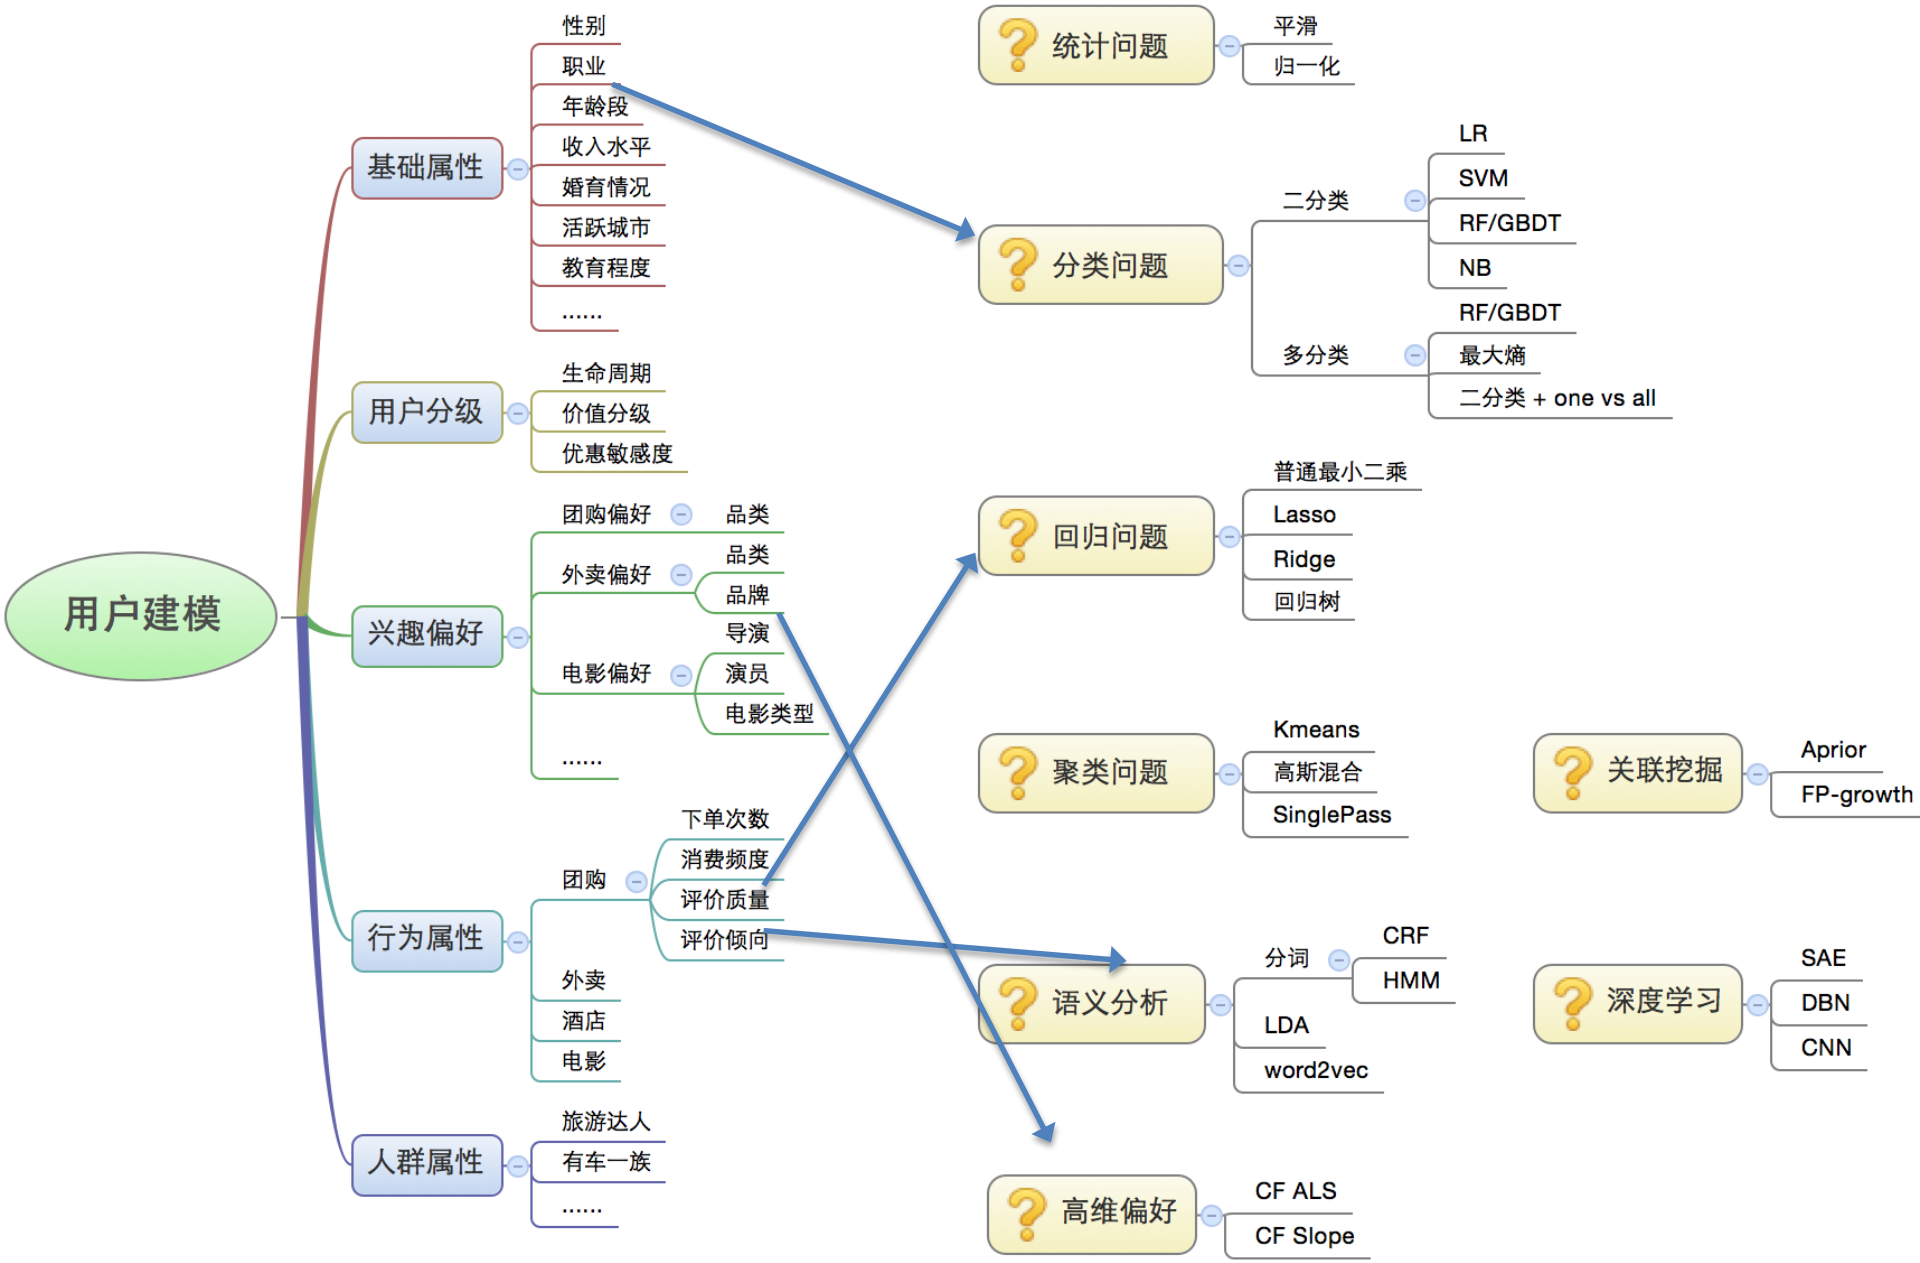
	第一轮迭代	第二轮迭代	第三轮迭代
召回	0.28	0.42	0.48
准确	0.63	0.68	0.74



	原始	离散化	特征选择
第一轮迭代	0.34	0.38	0.39
第二轮迭代	0.49	0.5	0.52
第三轮迭代	0.52	0.53	0.58

用户职业标签：学生身份识别

算法 - 问题及常用模型


用户建模
基础属性
性别
职业
年龄段
收入水平
婚育情况
活跃城市
教育程度
.....
用户分级
生命周期
价值分级
优惠敏感度
兴趣偏好
团购偏好
品类
外卖偏好
品类
品牌
电影偏好
导演
演员
电影类型
.....
行为属性
团购
下单次数
消费频度
评价质量
评价倾向
外卖
酒店
电影
人群属性
旅游达人
有车一族
.....
统计问题
平滑
归一化
分类问题
二分类
LR
SVM
RF/GBDT
NB
多分类
RF/GBDT
最大熵
二分类 + one vs all
回归问题
普通最小二乘
Lasso
Ridge
回归树
聚类问题
Kmeans
高斯混合
SinglePass
关联挖掘
Aprior
FP-growth
语义分析
分词
CRF
HMM
LDA
word2vec
深度学习
SAE
DBN
CNN
高维偏好
CF ALS
CF Slope

模型实例一

项目	有车一族标签挖掘
需求	1. 汽车服务推广活动需要精准圈定有车人群降低营销成本。
实现	1. 样本：问卷调查正样本+随机负样本 2. 特征：信息增益特征离散化+卡方/信息增益/互信息等特征选择 3. 模型：try SVM/MaxEnt/LR => SVM
效果	1. 离线评测：P93%，R85% 2. 线上对比：推送打开率**提升3倍**，下单率**提升5倍**！

SDCC 中国软件开发者大会 SOFTWARE DEVELOPER CONFERENCE CHINA

模型实例一

项目	常住地标签挖掘
需求	1. 决策支持：酒店需要分析用户下单与地域关系，决定是否上异地推荐模块。
实现	1. 样本：问卷调查 2. 模型：try LR/SVM/RF/GBDT=> LR 3. 多个LR模型组合
效果	1. 离线评测：P96%, R73% 2. 线上对比：新上异地模块点击率超越历史最佳“名店抢购”**1个百分点**！

实践 - 关于算法工程师的段子……

理想中的算法工程师

提出假设->收集数据->训练模型->解释结果

☺

实际中的算法工程师

提出假设->收集数据->预处理->预处理->训练模型->调试->调试->重新收集数据->预处理->收集更多数据->调试->调试->调试->…>放弃

☹

分享一

数据挖掘的天花板实数据本身！

ToDo：努力逼近这个效果而不是较劲！



分享二

实际应用中特征作用远大于模型！

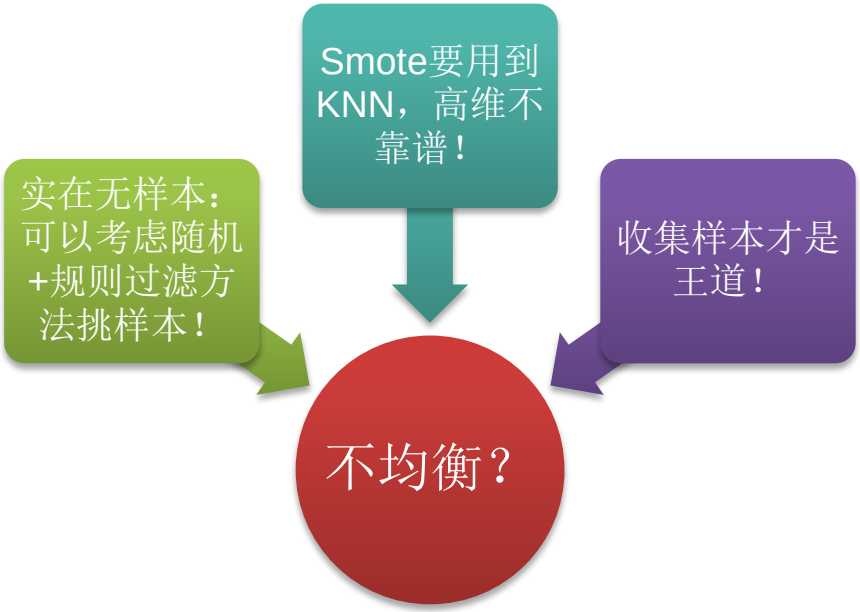
ToDo：在深度优化模型之前，先榨干数据特征的增益吧！特征至少带来80%+的收益。



分享三

关于样本:样本少/不均衡！

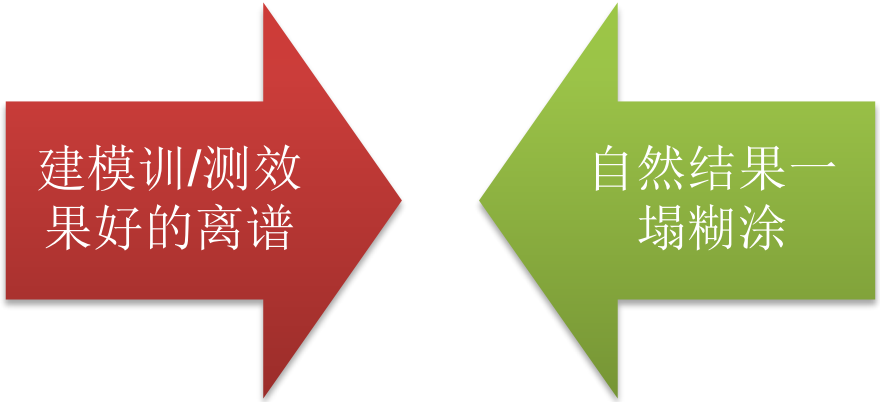
ToDo：1) SVM或TSVM, 2) under sampling/over sampling/~~SMOTE~~。



分享四

训练集特征分布和自然待测数据不一致。

ToDo：特征如果跟Label有直接关联就不要用了。



分享五

不要有把锤子，就把所有的问题当钉子。

ToDo：多了解模型的优缺点，选择合适的模型！



The mere formulation of a problem is far more essential than its solution.

--Albert Einstein

SDCC
中国软件开发者大会
SOFTWARE DEVELOPER CONFERENCE CHINA

CSDN
全球最大中文IT社区

Thank You !

sdcc.csdn.net